


# 数字图像处理


## 第八讲 边缘检测与细化



# 主要内容

- 边缘检测
- 细化





# 边缘检测


- 定义：边缘是指图像中灰度发生急剧变化的区域。
- 边缘与边界的区别
  - 边界是边缘
  - 边缘不一定是边界
  - 二值图像时，边界=边缘
- 如何反映：图像灰度的变化可以用图像的梯度反映。

# 边缘检测




- 边缘检测并不容易

- 图1



边缘比较明显

- 图2



边缘变得没有那么明显

# 边缘检测



- 边缘检测是图像处理和计算机视觉中的基本问题
  - 目的：标识数字图像中亮度变化明显的点。它存在于目标与背景、目标与目标、区域与区域之间。
  - 图像分割、图像压缩、特征提取等方面都把边缘检测作为基本的工具

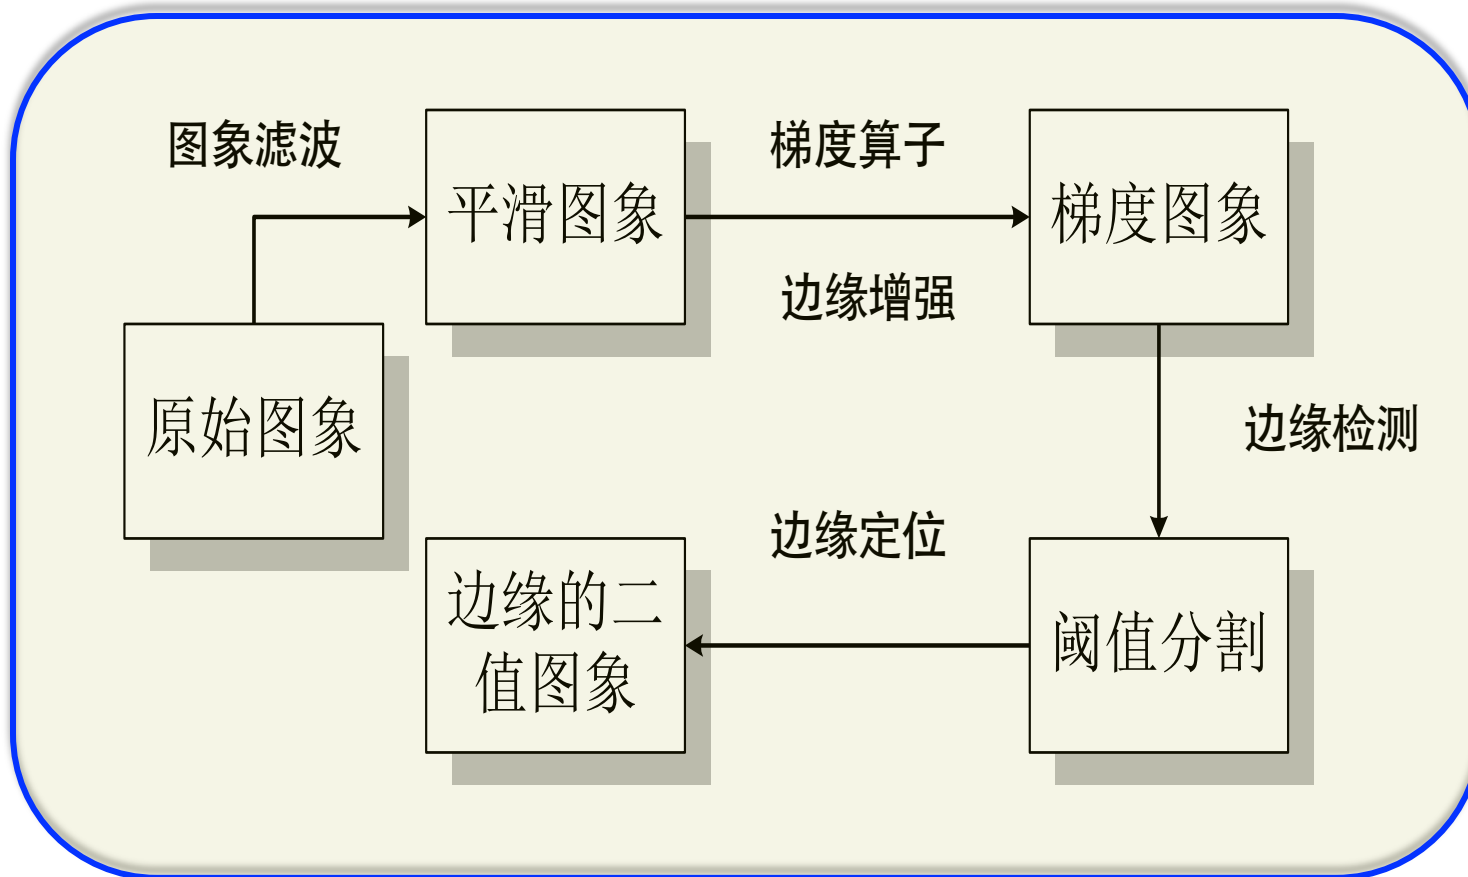



# 边缘检测的基本步骤




- 边缘检测算法的基本步骤
  - (1) **滤波**。滤波器的目标是降低噪声的影响。但有可能可能会导致边缘强度的损失。
  - (2) **增强**。增强算法将邻域中灰度有显著变化的点突出显示。一般通过计算梯度幅值完成。
  - (3) **检测**。检测算法的目标是检测出真边缘。最简单的边缘检测是梯度幅值阈值判定。
  - (4) **定位**。精确确定边缘的位置。

# 边缘检测的基本步骤



# 边缘检测



- **原理**：通过梯度的局部最大值来确定边缘
- **做法**：求连续图像 $f(x,y)$ 梯度的局部最大值及其方向。


$f(x,y)$ 沿 $r$ 的梯度

$$\frac{\partial f}{\partial r} = \frac{\partial f}{\partial x} \frac{\partial x}{\partial r} + \frac{\partial f}{\partial y} \frac{\partial y}{\partial r} = f_x \cos \theta + f_y \sin \theta$$

$$\text{使 } \frac{\partial f}{\partial r} \text{ 最大的条件是 } \frac{\partial \frac{\partial f}{\partial r}}{\partial \theta} = 0$$



# 边缘检测



- 计算梯度最大值及其方向

$$f_x \sin \theta_\varphi - f_y \cos \theta_\varphi = 0$$


$$\theta_\varphi = \tan^{-1} \left( \frac{f_y}{f_x} \right) \text{ 或 } \theta_\varphi + \pi$$

$$\text{梯度最大值 } \varphi = \sqrt{f_x^2 + f_y^2}$$




# 边缘检测中常用的梯度算子

- Roberts 算子
- Prewitt 算子
- Sobel 算子
- Laplacian 算子
- Marr(或LoG) 算子
- Canny 算子



算法从简单到复杂  
功能从单薄到完善

# Roberts算子



- 描述： 是一种利用局部差分算子寻找边缘的算子，它在 $2 \times 2$ 邻域上计算对角导数

$$g(i, j) = \sqrt{(f(i, j) - f(i + 1, j + 1))^2 + (f(i + 1, j) - f(i, j + 1))^2}$$

- 简化计算，用梯度的绝对值近似


$$g(i, j) = |f(i, j) - f(i + 1, j + 1)| + |f(i + 1, j) - f(i, j + 1)|$$

- 如果  $g(i, j) \geq \theta$  ，则为边缘； 否则不为边缘

# Roberts算子的计算



$$g(i, j) = |f(i+1, j+1) - f(i, j)| + |f(i+1, j) - f(i, j+1)|$$




$$f_x = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{bmatrix}$$

$$f_y = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & -1 & 0 \end{bmatrix}$$


对应于空间域滤波的模板计算

# Roberts算子点评



- 对于边界陡峭且噪声比较小的图像检测效果比较好。
- 对噪声比较敏感

# 示例



# Roberts算子效果



Lena的Roberts边缘

# Prewitt算子



- 思想：采用3x3领域

$$f'_i = f(i-1, j+1) + f(i, j+1) + f(i+1, j+1) \\ - f(i-1, j-1) - f(i, j-1) - f(i+1, j-1)$$

$$f'_j = f(i+1, j-1) + f(i+1, j) + f(i+1, j+1) \\ - f(i-1, j-1) - f(i-1, j) - f(i-1, j+1)$$

- 如果  $|f'_i| + |f'_j| \geq \theta$ , 则为边缘；否则不为边缘



# Prewitt算子的计算



$$g(i, j) = \{d_x^2(i, j) + d_y^2(i, j)\}^{\frac{1}{2}}$$


$$d_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad d_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

# Prewitt算子点评



- 考虑更多领域，对噪声有抑制作用。
- 较Roberts算子减少了对噪声的影响

# 示例



# Prewitt算子效果



Lena的Prewitt边缘

# Sobel算子



- 思想：不同近邻对梯度的贡献应该有所不同
- 做法：采用一种加权的方式

$$g(i, j) = \{d_x^2(i, j) + d_y^2(i, j)\}^{\frac{1}{2}}$$

$$d_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad d_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

# 其它变种




- Isotropic Sobel算子

$$H_1 = \begin{bmatrix} -1 & 0 & 1 \\ -\sqrt{2} & 0 & \sqrt{2} \\ -1 & 0 & 1 \end{bmatrix} \quad H_2 = \begin{bmatrix} -1 & -\sqrt{2} & -1 \\ 0 & 0 & 0 \\ 1 & \sqrt{2} & 1 \end{bmatrix}$$

- Sobel算子由于它更为精细，  
比Roberts, Prewitt算子更为常用

# 示例



# Roberts算子效果



Lena的Roberts边缘



# Prewitt算子效果




Lena的Prewitt边缘

# Sobel算子的效果




Lena的Sobel边缘

# 一阶算子与二阶算子



(a)




二阶算子可以判断  
“亮”与  
“暗”，从而可以通过  
过零点确定  
边缘

# 二阶算子




- Roberts, Prewitt以及Sobel算子只考虑一阶梯度信息。


邻域灰度直方图




一阶梯度阈值法




二阶过零点法  $f''(x)$





# 一阶算子与二阶算子

- 一阶导数的局部最大值或鞍点对应着二阶导数的零交叉点 (Zero crossing)。
- 这样通过求图像的二阶导数的零交叉点就能找到精确边缘点。
- 在二维空间，对应二阶导数算子有拉普拉斯算子。



# Laplacian算子

- 优势：是不依赖边缘方向的二阶微分算子，具有旋转不变性即各向同性的性质

$$\therefore \nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

$$\therefore \nabla^2 f = 4f(i, j) - f(i+1, j) - f(i-1, j) - f(i, j+1) - f(i, j-1)$$

$$H_1 = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

# Laplacian算子模板



- 标准模板及其它的一些变种

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

有时希望邻域中心点具有更大的权值

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix} \text{或}$$

$$\begin{bmatrix} 1 & -2 & 1 \\ -2 & 4 & -2 \\ 1 & -2 & 1 \end{bmatrix}$$



# Laplacian算子与一阶算子的比较

- 考虑四种基本结构（孤立点、端点、直线、以及阶跃）

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1^* & 0 \\ 0 & 0 & 0 \end{bmatrix} \quad \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1^* & 0 \\ 0 & 1 & 0 \end{bmatrix} \quad \begin{bmatrix} 0 & \vdots & 0 \\ & 1 & \\ 0 & 1^* & 0 \\ & 1 & \\ 0 & \vdots & 0 \end{bmatrix} \quad \begin{bmatrix} 0 & \vdots & \vdots & \dots \\ & 1 & 1 & \dots \\ 0 & 1^* & 1 & \dots \\ & 1 & 1 & \dots \\ 0 & \vdots & \vdots & \dots \end{bmatrix}$$

- 分别采用一阶算子和Laplacian算子



# 结果



一阶差分梯度图象  $G(x,y) = \max(|\Delta_x f(x,y)|, |\Delta_y f(x,y)|)$  向左和向下计算

$$\begin{bmatrix} 1 & & \\ 1^* & 1 & \\ & & \end{bmatrix} \begin{bmatrix} 1 & & \\ 1^* & 1 & \\ 1 & 1 & \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1^* & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & \\ 1 & \\ 1 & \end{bmatrix}$$

拉普拉斯图


$$\begin{bmatrix} 0 & +1 & 0 \\ +1 & -4^* & +1 \\ 0 & +1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 \\ 1 & -3^* & 1 \\ 1 & -2 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & 1 \\ 1 & -2^* & 1 \\ 1 & -2 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 & 0 \\ 1 & -1^* & 0 \\ 1 & -1 & 0 \end{bmatrix}$$

$a$ 图

$b$ 图

$c$ 图


$d$ 图




# Laplacian算子点评

- A图中对孤立的点，输出的是一个扩大略带模糊的点和线。
- B图和C图中对线的端点和线，输出的是加粗了的端点和线。
- D中对阶跃线，输出的只有一条线。
- 对梯度运算，梯度算子的灰度保持不变。而对拉氏算子，孤立点增加4倍，端点增加3倍，线增加2倍，界线不变。
- 拉氏算子在实际应用中对噪声敏感。因此实际中通常不直接使用


# 二阶算子对噪声敏感



# Marr算子



- Marr算子，也称为Laplacian of Guassian或LOG算子
- **思想：**考虑将高斯滤波和Laplacian算子结合在一起进行边缘检测




# Marr算子的步骤

- 第一步：对图像进行平滑高斯滤波

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{1}{2\pi\sigma^2}(x^2 + y^2)\right)$$

$$g(x, y) = f(x, y) * G(x, y)$$

- 第二步：对平滑后的图像采用Laplacian算子
- 第三步：通过零交叉点判断边缘
- 第四步：采用线性插值的方法估计边缘的位置




# 选择高斯滤波的原因

- 一个原因是高斯滤波可以平滑噪声，减少Laplacian算子对噪声的影响
- 另外一个原因是高斯滤波函数很平滑，任意阶可导，可以配合Laplacian算子使用。

$$h(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}, h'(x) = \frac{-x}{\sqrt{2\pi}\sigma^3} e^{-\frac{x^2}{2\sigma^2}}, h''(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2} \left( \frac{x^2}{\sigma^2} - 1 \right)}$$

# Marr算子



- 联合形式

$$h(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

$$LoG = \nabla^2 h(x, y) = \frac{\partial^2 h}{\partial x^2} + \frac{\partial^2 h}{\partial y^2}$$


$$= \frac{1}{\pi\sigma^4} \left( \frac{x^2 + y^2}{2\sigma^2} - 1 \right) e^{-\frac{x^2+y^2}{2\sigma^2}}$$

# Marr算子的计算




- 离散拉普拉斯高斯模板 ( $5 \times 5$ ,  $\delta=2$ )

$$\begin{vmatrix} 0 & 0 & -1 & 0 & 0 \\ 0 & -1 & -2 & -1 & 0 \\ -1 & -2 & 16 & -2 & -1 \\ 0 & -1 & -2 & -1 & 0 \\ 0 & 0 & -1 & 0 & 0 \end{vmatrix}$$







# Marr算子的其它变种

- 高斯滤波可以进一步推广为DoG滤波


$$DOG = \frac{1}{2\pi\sigma_1^2} e^{-\frac{x^2+y^2}{2\sigma_1^2}} - \frac{1}{2\pi\sigma_2^2} e^{-\frac{x^2+y^2}{2\sigma_2^2}}$$

在实际应用中，取  $\sigma_1/\sigma_2 = 1.6$ ，此时

$$DOG \rightarrow LOG$$

DoG:  
Difference  
of Gaussian


- 更加精细



# Marr算子点评


- 过零点 (Zero-crossing) 的检测与参数 $\delta$ 有关，但边缘位置与 $\delta$ 的选择无关。 $\Delta$ 的选择是个问题
  - 若只关心全局性的边缘可以选取比较大的邻域(如 $\delta = 4$  时，邻域接近40个像素宽)来获取明显的边缘。
- 可能会因为过度平滑形状，丢失一些边缘；

# Marr算子效果





Marr边缘  
Delta=2

# Marr算子效果



Marr边缘  
 $\text{delta}=4$

# 一阶算子与二阶算子





(a)



(b)

一阶Sobel算子

# 一阶算子与二阶算子




二阶Laplacian算子

# Canny算子



- 最优的阶梯型边缘检测算法
- 原理
  - 图像边缘检测必须满足两个条件：一能有效地抑制噪声；二必须尽量精确确定边缘的位置。
  - 根据对信噪比与定位乘积进行测度，得到最优化逼近算子。这就是Canny边缘检测算子。
  - 类似与Marr (LoG) 边缘检测方法，也属于先平滑后求导数的方法。


# Canny算子的基本步骤



- step1:用高斯滤波器平滑图像；
- step2:用一阶偏导的有限差分来计算梯度的幅值和方向；
- step3:对梯度幅值进行非极大值抑制；
- step4:用双阈值算法检测和连接边缘。



# Canny算子



- Step1: 用高斯滤波器平滑图像

$$H(x, y) = e^{-\frac{x^2 + y^2}{2\sigma^2}}$$

$$G(x, y) = f(x, y) * H(x, y)$$

# Canny算子



- step2:一阶差分卷积模板:

$$H_1 = \begin{vmatrix} -1 & -1 \\ 1 & 1 \end{vmatrix} \quad H_2 = \begin{vmatrix} 1 & -1 \\ 1 & -1 \end{vmatrix}$$


$$\varphi_1(m, n) = f(m, n) * H_1(m, n)$$

$$\varphi_2(m, n) = f(m, n) * H_2(m, n)$$

$$\varphi(m, n) = \sqrt{\varphi_1^2(m, n) + \varphi_2^2(m, n)}$$


$$\theta_\varphi(m, n) = \tan^{-1} \frac{\varphi_2(m, n)}{\varphi_1(m, n)}$$

# Canny算子



- Step3:非极大值抑制
  - 仅仅得到全局的梯度并不足以确定边缘，因此为确定边缘，必须保留局部梯度最大的点，而抑制非极大值。（non-maxima suppression, NMS）
  - 解决方法：利用梯度的方向。

$$\xi[i,j] = \text{Sector}(\theta[i,j])$$



1	2	3
8		4
7	6	5

# Canny算子



- Step3 (续)
  - 四个扇区的标号为0到3，对应3\*3邻域的四中可能组合。
  - 在每一点上，邻域的中心像素 $M$ 与沿着梯度线的两个像素相比。如果 $M$ 的梯度值不比沿梯度线的两个相邻像素梯度值大，则令 $M=0$ 。
  - 即：


$$N[i,j] = NMS(M[i,j], \xi[i,j])$$

# Canny算子



- Step4: 阈值化
  - 减少假边缘段数量的典型方法是对 $N[i, j]$ 使用一个阈值。将低于阈值的所有值赋零值。但问题是如何选取阈值？
  - 解决方法：双阈值算法。
    - 设置两个阈值 $a1, a2$ ，通常 $2.5 a1 = a2$
    - $a2$ 阈值下假边缘少，但是轮廓有间断；对于轮廓的端点，利用 $a1$ 阈值的8邻点位置寻找可以连接到轮廓上的边缘。算法不断地收集边缘，知道将轮廓连接起来为止


# Canny算子效果



Canny边缘


$\alpha=2$

# Canny算子效果



Canny边缘

$\alpha=4$




# 边缘检测算法例子

- `function my_edge_detection()`
- 
- `I=imread('lenna.png');` % 提取图像
- `I=I(:,:,1);`
- 
- `BW1=edge(I,'sobel',0.04);` %用SOBEL算子进行边缘检测
- `BW2=edge(I,'roberts',0.04);` %用Roberts算子进行边缘检测
- `BW3=edge(I,'prewitt',0.04);` %用prewitt算子进行边缘检测
- `BW4=edge(I,'log');` %用log算子进行边缘检测
- `BW5=edge(I,'canny');` %用canny算子进行边缘检测



# 边缘检测算法例子



- `subplot(2,3,1), imshow(BW1);`
- `title('sobel edge check');`
- `subplot(2,3,2), imshow(BW2);`
- `title('roberts edge check');`
- `subplot(2,3,3), imshow(BW3);`
- `title('prewitt edge check');`
- `subplot(2,3,4), imshow(BW4);`
- `title('log edge check');`
- `subplot(2,3,5), imshow(BW5);`
- `title('canny edge check');`

# 边缘检测算法效果图



sobel edge check



roberts edge check



prewitt edge check




log edge check



canny edge check



# Canny算法点评




- 实际效果通常要优于其它算子，特别对于有噪声，或者存在假边缘的图像

# 主要内容

- 边缘检测
- 细化



# 细化



- 1) 什么是细化?
- 2) 回顾一些基本概念
- 3) 细化的要求
- 4) 细化算法

# 细化 (thinning)




- 定义

- 细化是一种二值图像处理运算。可以把二值图像区域缩成线条，以逼近区域的中心线。
- 细化的目的是减少图像成分，只留下区域最基本的信息，以便进一步分析和处理。
- 细化一般用于文本分析预处理阶段。

# 细化示例






# 回顾一些基本概念



- (1) 近邻
  - 4邻点 (4-neighbors) : 如果两个像素有公共边界, 则称它们互为4邻点。
  - 8邻点 (8-neighbors) : 如果两个像素至少共享一个顶角, 则称它们互为8邻点。
- (2) 连通
  - 一个像素与它的4邻点是4连通 (4-connected) 关系;
  - 一个像素与它的8邻点是8连通 (8-connected) 关系;




# 路径、前景背景



- (3) 路径
  - 从像素0到像素n的路径是指一个像素序列,  $0, 1, \dots, k, \dots, n$ , 其中k与k+1像素互为邻点。
  - 如果邻点关系是4连通的, 则是4路径;
  - 如果邻点关系是8连通的, 则是8路径;
- (4) 前景背景
  - 图像中值为1的全部像素的集合称为前景 (foreground), 用S来表示。



# 连通性、连通分支、边界



- (5) 连通性

- 已知像素  $p, q \in S$ ，如果存在一条  $p$  到  $q$  的路径，且路径上全部像素都包含在  $S$  中，则称  $p$  与  $q$  是连通的。
- 连通性具有：自反性、互换性和传递性。

- (6) 连通分支

- 一个像素集合，如果集合中每一个像素与其他像素连通，则称该集合是连通分支 (connected component)。

- (7) 简单边界点

- $S$  中的一个边界点  $P$ ，如果其邻域中 (不包括  $P$  点) 只有一个连通成分，则  $P$  是简单边界点。

# 边界点



- 判断下图中哪些是简单边界点?

A不是				B是				C是				D是				E不是		
0	1	1		0	1	1		0	0	1		0	0	0		0	1	1
0	P	1		0	P	1		0	P	1		0	P	0		0	P	0
1	0	0		0	1	0		1	1	0		0	0	1		1	1	0

# 细化要求



- (1) 连通区域必须细化成连通线结构；
- (2) 细化结果至少是8连通的；
- (3) 保留终止线的位置；
- (4) 细化结果应该近似于中轴线；
- (5) 由细化引起的附加突起应该是最小的。

# 细化算法



- 思想：在至少 $3 \times 3$ 邻域内检查图像前景中的每一个像素，迭代削去简单边界点，直至区域被细化成一条线。

# 细化算法



- 算法描述：
  - 对于每一个像素，如果
  - A) 没有上邻点（下邻点、左邻点、右邻点）；
  - B) 不是孤立点或孤立线；
  - C) 去除该像素点不会断开连通区域
  - D) 删除该像素点；
  - E) 重复A-D步骤直到没有像素点可以去除。

# 具体步骤



- 每次细化分4步 (不去除只有一个邻点)，具体过程如下：

- (1) 八连通下北向边界点 ( $n=0, p=1$ ) 可删除条件

$$w\bar{s}e + \bar{w}(nw) + (ne)\bar{e} + \bar{e}(se)\bar{s} + \bar{s}(sw)\bar{w} = 0$$

- 上式排除下面5种情况：

nw	n	ne
w	p	e
sw	s	se

	0			1	0				0	1			0			0	
1	P	1		0	P				P	0			P	0		0	P
	0												0	1		1	0






	0										0	1			1	0
1	P	1		0	P			P	0			P	0		0	P
	0			1	0			0	1			0				0

- **(3) 八连通下的西向边界点 ( $w=0, p=1$ ) 可删除条件:**

[illegible]



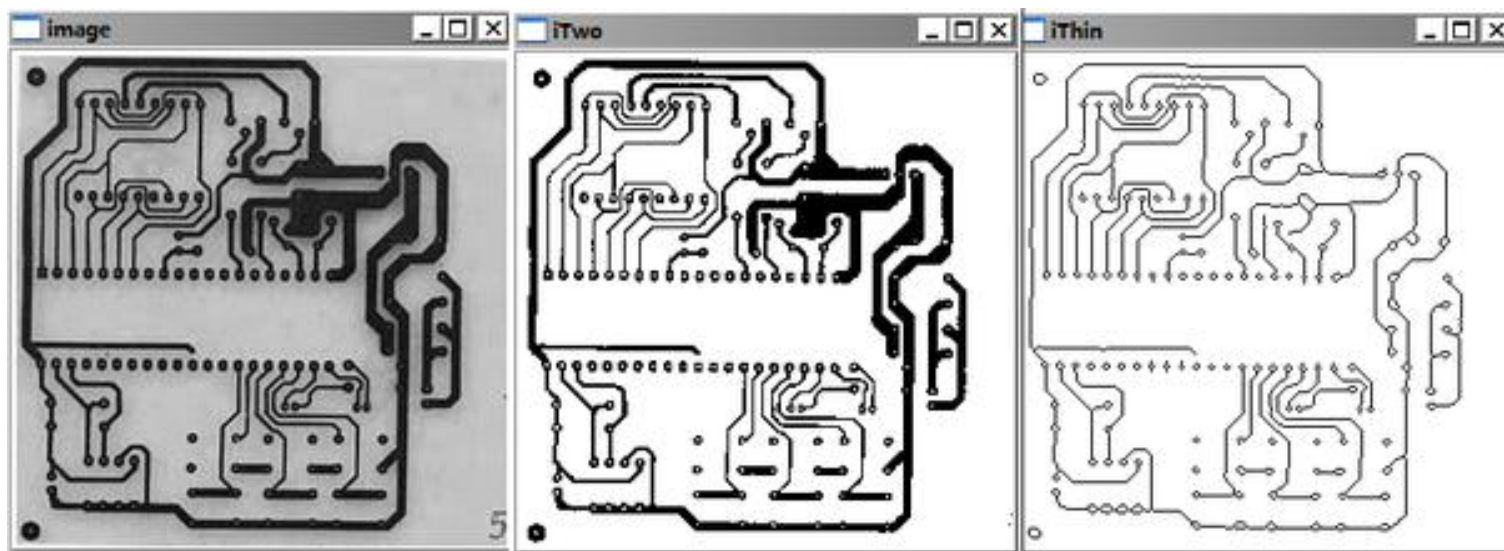

- (4) 八连通下的东向边界点 ( $e=0, p=1$ ) 可删除条件:

$$n\bar{w}s + \bar{s}(se) + (ne)\bar{n} + \bar{e}(nw)\bar{n} + \bar{s}(sw)\bar{w} = 0$$

- 排除了下面5种情况:

	1						0	1		1	0							
0	P	0			P	0		P	0		0	P	0		0	P	0	
	1				0	1									1	0		


# 细化效果





# 要点小结

- 边缘检测
  - 边缘检测的基本步骤及其意义
  - 边缘与边界的区别联系
  - 边缘检测的核心在于梯度计算
  - 边缘检测常用的算子及其原理
- 细化
  - 细化的定义，原理及其意义



# 下一讲

